

SECONDARY LANGUAGE VERSION:

Emotion Detection in Social Media with Retrieval-Augmented Generation (RAG) Justification

Bachelor Semester Project 5

Student Name: SOUSA
FARIA João Bernardo
ID:0232421751
University Name: University of
Luxembourg
Email:
joao.sousa.003@student.uni.lu

Preferred Language: French

Tutor Name: LAMSIYAH
Salima
University Name: University of
Luxembourg
Email:
salima.lamsiyah@uni.lu

Le projet a été développé par l'étudiant **João Bernardo Sousa Faria**, sous la supervision de leur tutrice **Salima Lamsiyah**.

Ce projet explore la détection d'émotion dans les textes des réseaux sociaux, avec attention particulière sur l'explicabilité. Les modèles modernes de Deep Learning sont capables de classifier les émotions avec précision mais leurs prédictions sont souvent opaques. Ce facteur limite la confiance et convivialité dans les applications sensibles comme la surveillance de la santé mentale ou l'analyse d'opinion. Pour remédier à cette limitation, le projet propose un système de détection d'émotion qui utilise une combinaison de **classification multi-étiquettes** avec **génération augmentée par récupération (RAG)** pour produire des justifications basées **sur preuve** pour leurs prédictions.

Le système cible du contenu court et informel des réseaux sociaux, spécifiquement des commentaires de Reddit, où l'expression émotionnelle et fréquemment subtile et plusieurs émotions peuvent être présentes simultanément. L'approche repose sur la mise au point ("fine-tuning" en anglais) d'un **modèle de transformateur basé sur RoBERTa** sur l'**ensemble de données GoEmotions**, qui contient environ 58,000 commentaires annotés avec 27 étiquettes émotionnelles précises, avec une catégorie additionnelle pour "neutre". Comme la distribution des émotions dans l'ensemble de données est hautement déséquilibré, la tâche est encadrée comme un problème de classification multi-étiquettes qui utilise

de sorties de forme sigmoïde plutôt qu'une seule décision softmax.

Pour améliorer la performance de la classification, le projet introduit l'**optimisation du seuil de décision par étiquette**. Plutôt que d'utiliser un seuil global unique, les seuils individuels sont optimisés sur un ensemble de/pour validation pour maximiser les F1 scores pour chaque émotion distincte. Cette phase de post-traitement améliore notamment les moyennes de F1 scores micro et macro, spécialement pour les émotions qui sont moins communs.

Au-delà de la précision de prédiction, le projet améliore aussi l'interprétabilité à travers un **mécanisme de justification basé sur la récupération**. Commentaires qui sont sémantiquement similaires sont récupérés de l'ensemble de données de/pour entraînement et filtrés pour partager des émotions avec le texte saisi. Ensuite, les mêmes exemples sont utilisés pour générer des explications qui relient des signaux émotionnels dans le commentaire saisi aux motifs que sont observées en réalité dans les messages écrits par l'humain. Cette séparation entre la prédiction et l'explication assure de la transparence sans que la performance de classification soit affectée.

En général, le projet démontre que la combinaison de la forte classification d'émotion avec des explications augmentées par la récupération conduit à un système de détection d'émotion plus transparent et digne de confiance.